Trabalho 01 - Busca Não Informada, Busca Informada e Busca Local

Lorena Ávila de Souza Silva[1]

[1]Curso de Engenharia de Computação - CEFET-MG, campus Divinópolis
Disciplina de Inteligência Artificial - 2026/2

lorenaavila15@outlook.com

Abstract. *This report presents the implementation and experimental analysis of uninformed, informed, and local search algorithms developed for Assignment 01. The experiments compare BFS, DFS, Uniform-Cost Search, Greedy Best-First Search, and A* in a weighted grid, and Hill Climbing and Random-Restart Hill Climbing in the 8-Queens problem. Quantitative results show that A* with Manhattan reduced expansions from 74 (UCS) to 43 while preserving the optimal cost of 29, whereas Hill Climbing achieved a 12% success rate compared to 100% for Random-Restart [Russell and Norvig 2021].*

Resumo. *Este relatório apresenta a implementação e a análise experimental dos algoritmos de busca desenvolvidos no Trabalho 01. Os experimentos comparam BFS, DFS, Busca de Custo Uniforme, Busca Gulosa e A* em um ambiente ponderado, além de Hill Climbing e Random-Restart Hill Climbing no problema das 8 rainhas. Os resultados quantitativos mostram que o A* com Manhattan reduziu as expansões de 74 (UCS) para 43 mantendo o custo ótimo de 29, enquanto o Hill Climbing obteve 12% de sucesso frente aos 100% do Random-Restart.*

1. Introdução

O presente trabalho aborda a modelagem e a resolução de problemas clássicos de Inteligência Artificial divididos em duas frentes: a busca em ambientes ponderados em grade e a otimização local aplicada ao problema das 8 rainhas. O objetivo principal é comparar o comportamento prático de diferentes estratégias de busca frente a métricas rigorosas de desempenho, como número de passos, custo acumulado, nós gerados e expandidos, picos de memória e tempo de execução.

A análise busca responder a questões fundamentais sobre a divergência entre menor número de passos e menor custo real, o impacto da escolha da heurística na eficiência do A* e da Busca Gulosa, e as limitações de ótimos locais enfrentadas pelo Hill Climbing puro em contraste com o sucesso do Random Restart.

2. Representação e implementação

2.1. Parte 1 - Busca não informada e informada

A representação do ambiente consiste numa grade ponderada onde cada célula possui um custo associado de transição. As buscas (BFS, DFS, UCS, Gulosa e A*) utilizam estruturas de dados nativas: `deque` para a fila da BFS, pilhas em listas para a DFS, e filas

de prioridade (`heapq`) para UCS, Gulosa e A*, garantindo desempates determinísticos baseados em contadores de inserção.

O rastreamento de estados descobertos foi implementado no momento da inserção na fronteira (para BFS e DFS, evitando loops em grafos finitos com ciclos) e por meio de dicionários de melhor custo conhecido (`cost_so_far` / `g_score`) para UCS e A*, permitindo o descarte de entradas obsoletas. Na Busca Gulosa, cada estado entra na fronteira uma única vez, enquanto UCS e A* reinserem quando o custo melhora. O teste de objetivo é feito estritamente ao retirar da fronteira (o objetivo não conta como expandido), e a reconstrução do caminho utiliza um dicionário de pais (`parent`).

2.2. Heurísticas

As heurísticas utilizadas foram as distâncias de Manhattan e Euclidiana. Elas são admissíveis porque cada movimento ortogonal muda a distância Manhattan em exatamente 1 e custa pelo menos 1, enquanto obstáculos e terrenos caros apenas aumentam o custo real de travessia. Logo, o custo real restante é sempre $\geq$ Manhattan $\geq$ Euclidiana, sendo a Manhattan uma estimativa mais próxima e informativa do custo real em grades ortogonais.

2.3. Problema das 8 rainhas

O problema modela o tabuleiro como um vetor de 8 inteiros, onde o índice é a coluna e o valor é a linha (gerado com `randrange(8)` por coluna). A função de avaliação $h(s)$ calcula o número de pares em conflito. A vizinhança de tamanho 56 explora todas as colunas e linhas alternativas. O Hill Climbing avalia os 56 vizinhos, escolhe o primeiro entre os de menor h e só aceita o movimento se houver melhora estrita ($h_{novo} < h_{atual}$), sem aceitar movimentos laterais. O Random Restart utiliza `random.Random` para reinicializar o tabuleiro até 50 vezes em caso de falha.

3. Metodologia experimental

Os experimentos foram executados em ambiente Linux (Ubuntu) utilizando Python 3.12.3, sem dependências externas além das bibliotecas padrão. O mapa utilizado foi o `data/mapa_teste.txt`. Os comandos de reprodução são `python3 -m scripts.run_experiments` e `python3 -m unittest discover -s tests -v`. As métricas de tempo foram obtidas isolando a leitura do arquivo e calculando a mediana de 30 execuções independentes via `time.perf_counter()`, servindo como métrica secundária e sujeita a variações entre rodadas.

Para a Parte 2, executou-se o Hill Climbing e o Random Restart sobre 100 sementes (0 a 99). Cada movimento aceito conta como uma iteração; a contagem de estados avaliados inclui o estado inicial e todas as avaliações de vizinhos (incluindo a varredura final sem melhora); e no Random Restart, *restarts* representa o número de tentativas menos 1.

Repositório: `https://github.com/Lorenaavila20/ia-trabalho01`
Tag da entrega final: `entrega-final`.

4. Resultados

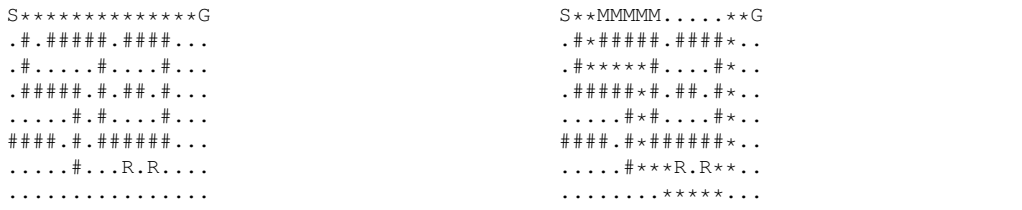
4.1. Parte 1 - Busca não informada e informada

A Tabela 1 consolida os resultados obtidos no mapa de teste público.

Tabela 1. Resultados dos algoritmos de busca no mapa de teste.

Algoritmo	Heurística	Passos	Custo	Gerados	Expandidos	Pico fronteira	Memória	Tempo (ms)
BFS	-	15	40	66	59	9	66	0.088
DFS	-	15	40	21	15	6	21	0.029
UCS	-	29	29	77	74	6	77	0.151
Gulosa	Manhattan	15	40	21	15	6	21	0.034
Gulosa	Euclidiana	15	40	21	15	6	21	0.032
A*	Manhattan	29	29	60	43	15	58	0.109
A*	Euclidiana	29	29	72	60	12	72	0.134

A Figura 1 ilustra visualmente os caminhos encontrados pelos algoritmos (sendo que DFS e Busca Gulosa produziram o mesmo caminho da BFS neste mapa).



BFS, DFS e Gulosa: 15 passos, custo 40 — UCS e A* (Manhattan): 29 passos, custo 29

Figura 1. Caminhos encontrados pelos algoritmos no mapa público.

O A* com Euclidiana também encontrou custo 29, em 29 passos, mas por uma rota diferente nos últimos passos (passa pela célula $(1, 14)$ em vez de $(0, 13)$): há mais de um caminho ótimo, e os critérios de desempate decidem qual deles é retornado.

4.2. Parte 2 - Busca local e 8 rainhas

A Tabela 2 resume os experimentos realizados com as 100 sementes (0 a 99).

Tabela 2. Resultados dos métodos de busca local no problema das 8 rainhas.

Métrica	Hill Climbing	Random Restart
Execuções	100	100
Soluções encontradas	12	100
Taxa de sucesso (%)	12%	100%
Média de iterações	3.28	24.72
Mediana de iterações	3.0	17.5
Média de estados avaliados	240.68	1826.64
Média de reinícios	N/A	6.76
Máximo de reinícios	N/A	42

A primeira falha do HC, na seed 0, teve estado inicial `[6, 6, 0, 4, 7, 6, 4, 7]` ($h = 9$). A trajetória de h foi $[9, 6, 4, 3, 2]$, estagnando num mínimo local com $h = 2$ (tabuleiro final `[6, 3, 5, 2, 1, 6, 4, 7]`). Nesse estado final, os conflitos restantes são um par na mesma linha (colunas 0 e 5) e um par na diagonal (colunas 3 e 4); dos 56 vizinhos, 0 melhoravam, 3 empatavam e 53 pioravam, e nenhum movimento lateral único levou a uma melhora.

5. Discussão

A análise abaixo responde de forma estruturada às questões centrais propostas [Russell and Norvig 2021]:

- **Q1 e Q2 (Diferença entre número de ações e custo / Comportamento de BFS, DFS e UCS):** A BFS encontra o menor caminho em número de ações (15 passos na Tabela 1), mas não em custo (40), pois expande nós por nível sem ponderar os custos das células. A UCS garante o custo ótimo (29) por expandir nós em ordem crescente de custo acumulado, ainda que exiba maior esforço (74 nós expandidos).
- **Q3 (Ordem de expansão da DFS):** A DFS encontrou uma solução de 15 passos e custo 40 porque os sucessores são empilhados em ordem inversa na pilha, fazendo com que o Norte saia primeiro, e o Leste seja expandido antes do Sul. O objetivo está a leste do início e a DFS seguiu a linha 0. Conforme demonstrado no mapa pequeno do arquivo de testes (`tests/test_search.py`, no teste de comparação onde a BFS dá 2 passos e a DFS dá 8), evidencia-se fortemente a influência da ordem de expansão sobre o caminho percorrido.
- **Q4 (Desempenho da Busca Gulosa):** A Busca Gulosa foi rápida (15 expansões, 21 gerados), mas gerou custo subótimo (40). O custo subiu porque, a partir de S, avaliando com Manhattan, o vizinho a leste tem $h = 14$ e o do sul tem $h = 16$, fazendo com que a Gulosa siga rigidamente pela linha 0, mesmo sobre terrenos de alto custo (os cinco M, acumulando 30 dos 40 pontos de custo).
- **Q5 e Q6 (Comparação UCS vs A* e heurísticas):** O A* com Manhattan reduziu as expansões de 74 (UCS) para 43, mantendo o custo ótimo de 29. Na Busca Gulosa, a troca de heurística entre Manhattan e Euclidiana não alterou as métricas (mesmo caminho, 21 gerados, 15 expandidos, custo 40). Já no A*, a troca elevou as expansões de 43 (Manhattan) para 60 (Euclidiana), pois a Euclidiana fornece estimativas menores, logo menos informativas.
- **Q7 (Admissibilidade):** Ambas as heurísticas são admissíveis porque cada movimento ortogonal muda a distância Manhattan em exatamente 1 e custa pelo menos 1, enquanto obstáculos e terrenos caros apenas aumentam o custo real. Logo, custo real $\geq$ Manhattan $\geq$ Euclidiana.
- **Q8 (Busca Gulosa vs Hill Climbing):** A Busca Gulosa escolhe o melhor nó de toda a fronteira e guarda os nós já explorados, podendo retomar ramos alternativos. O Hill Climbing guarda apenas o estado atual, sem lembrar alternativas ou gerar um caminho, resultando unicamente na configuração final atingida.
- **Q9 (Paisagem de busca local e seed 0):** Na seed 0, o Hill Climbing iniciou com $h = 9$, seguiu a trajetória $[9, 6, 4, 3, 2]$ em 4 iterações e avaliou 281 estados até estagnar num mínimo local com $h = 2$, onde 0 vizinhos eram melhores, 3 empatavam e 53 pioravam.
- **Q10 (Eficácia do Random Restart):** Com uma taxa de sucesso estimada em 12% por tentativa, a probabilidade teórica de falha em 51 tentativas independentes é de $(1 - 0.12)^{51} \approx 0.15\%$. O número esperado de reinícios é $1/0.12 - 1 \approx 7.3$ (observou-se 6.76 em média). Contudo, os reinícios não eliminam a limitação de que cada tentativa continua sendo um Hill Climbing vulnerável a mínimos locais (88% de chance de falhar por tentativa); a garantia é apenas probabilística e limitada pelo teto de 50 reinícios (sendo que o máximo observado foi 42).

- **Q11 (Completude e optimalidade):** Nas condições deste trabalho (grade finita com controle de estados descobertos na inserção): a BFS é completa e ótima apenas em número de ações (custo 40); a UCS é completa e ótima em custo (custo 29, pois todos os custos ≥ 1); o A* é completo e ótimo por usar heurística admissível (custos 29 com 43 e 60 expansões); a DFS e a Gulosa são completas por marcarem os visitados (evitando loops), mas não são ótimas (custo 40); e o Hill Climbing é incompleto, enquanto o Random Restart possui apenas completude probabilística limitada pelo teto de reinícios, alcançando 100% de sucesso empírico nos testes.

6. Conclusão

O trabalho permitiu consolidar a compreensão prática entre buscas cegas, informadas e locais. O A* com Manhattan atingiu 43 expansões contra 74 da UCS, com o mesmo custo e menos expansões neste mapa. Já o Hill Climbing puro obteve 12% de sucesso, enquanto o Random Restart alcançou 100% de sucesso, confirmando a eficácia e os limites das abordagens locais neste cenário.

Contribuições dos autores

A autora implementou e testou os algoritmos, executou os experimentos e redigiu o relatório.

Declaração de uso de IA

Foi utilizado o Claude (Anthropic), via chat, como apoio para planejamento e esclarecimento do enunciado, explicação em linguagem natural da lógica dos algoritmos, criação de casos de teste, revisão do código, estrutura do script de experimentos e revisão crítica do relatório. Algumas formulações da Discussão foram revisadas e aprimoradas a partir de sugestões do Claude; todos os resultados, contas e conclusões foram verificados criticamente pela autora. Os detalhes estão em `IA_USAGE.md`.

Referências

Russell, S. and Norvig, P. (2021). *Artificial Intelligence: A Modern Approach*. Pearson, 4th edition.